

¿Qué tan lejos viaja un detector de basura?

Detección cross-domain de residuos urbanos en imágenes de mano, dashcam y dron

Jairzinho Santos

Universidad Nacional de Ingeniería, Lima, Perú

Visión Computacional — Maestría en Inteligencia Artificial, 2026-I

Resumen—El monitoreo automatizado de basura suele evaluarse dentro de un solo dominio de imagen, pero los despliegues reales mezclan reportes ciudadanos, cámaras vehiculares y drones. Estudiamos cuánto se degradan los detectores de residuos urbanos entre tres dominios públicos —TACO (mano), RoLID-11K (dashcam) y UAVVaste (dron)— bajo un único protocolo auditado de evaluación. Nuestra curación destapó siete defectos en los datasets publicados, en particular fuga a nivel de video en los splits oficiales de RoLID-11K: el 58.2 % del test comparte video de origen con el entrenamiento, y un modelo entrenado con ese traslape obtiene +21 % de AP_{50} sobre el mismo test. Comparamos Faster R-CNN, un segmentador FCN e interpretabilidad basada en CAM contra una referencia YOLOv11, y medimos una degradación cross-domain de 82 % en mAP_{50} , dominada por la escala de los objetos (mediana de 22 px en dashcam, por debajo del ancla FPN más pequeña). Elevar la resolución a 1024 px recupera hasta 8.3 puntos de AP_{50} y 5.8 de AP_S . Publicamos código, pesos y splits auditados.

Palabras clave—detección de basura, evaluación cross-domain, auditoría de datasets, objetos pequeños

I. INTRODUCCIÓN

La basura no recolectada afecta la salud pública, el turismo y los presupuestos municipales, y su monitoreo aún depende de inspección manual de cobertura limitada. La visión computacional promete monitoreo continuo y de bajo costo, y el trabajo reciente ha producido datasets públicos de detección de basura en escenarios complementarios: fotografías de mano a nivel de calle (TACO [1]), dashcams frontales (RoLID-11K [2]), imágenes de dron (UAVVaste [3]) y cámaras ojo de pez en camiones recolectores (StreetView-Waste [4]). Cada benchmark, sin embargo, se evalúa *dentro de su dominio*; si un detector entrenado en un punto de vista sigue siendo útil en otro —la situación que enfrenta cualquier ciudad que despliegue sensores mixtos— no había sido medido.

Este trabajo pregunta: *¿cuánto se degrada la detección de basura urbana entre dominios de imagen, y qué importa más para cerrar la brecha: la arquitectura, la resolución de entrada o la higiene de los datos de entrenamiento?* Responderla exigió más que entrenar detectores. Auditar los tres datasets destapó siete defectos (Sección III), incluida la fuga a nivel de video en los splits oficiales de RoLID-11K que infla los baselines publicados, colisiones de nombres de archivo y marcos de anotación EXIF inconsistentes en TACO y UAVVaste. Construimos por ello un pipeline de curación auditado con splits congelados conscientes de grupos,

y evaluamos todos los modelos contra los mismos ground truths.

Nuestras contribuciones son: (i) una auditoría documentada de tres datasets públicos de basura, con splits corregidos y publicados; (ii) la primera matriz de evaluación cross-domain entre imágenes de mano, dashcam y dron; (iii) la cuantificación de la inflación por fuga en el protocolo oficial de RoLID-11K (+21 % de AP_{50} por memorización de escena); (iv) una comparación controlada de detectores clásicos afinados, segmentación e interpretabilidad contra una referencia moderna en tiempo real, incluyendo una ablación de resolución para objetos pequeños y un estudio de granularidad de clases (6 contra 5 clases de material).

II. TRABAJO RELACIONADO

Datasets de basura. TACO [1] aporta 1,500 imágenes de mano con 60 categorías y polígonos de segmentación. RoLID-11K [2] contribuye 11.5k cuadros de dashcam con una sola clase *litter* y estadísticas marcadas de objeto pequeño. UAVVaste [3] cubre vistas de dron a baja altura. StreetView-Waste [4] apunta a cámaras ojo de pez de camiones recolectores; sus enlaces de descarga no estuvieron disponibles durante este trabajo. Detect-waste [5] armonizó varias de estas fuentes; ZeroWaste [6] aborda la clasificación industrial, un dominio que excluimos deliberadamente.

Detección bajo restricciones. TrashDet [7] busca detectores TinyML sobre TACO y alcanza 19.5 de mAP_{50} en un subconjunto de cinco clases: evidencia de que las cifras absolutas de este problema son estructuralmente bajas, lo que motiva nuestro énfasis en cantidades *relativas* entre dominios. Los autores de RoLID evalúan detectores modernos, con cabezas transformer (CO-DETR) superando a las variantes YOLO por más de 20 puntos de AP_{50} , consistente con el régimen extremo de objetos pequeños.

Métodos. Nos apoyamos en Faster R-CNN [8] y su RPN, la segmentación totalmente convolucional [9], la interpretabilidad por activación de clase [10], [11], [12], YOLOv11 [13] como referencia en tiempo real, TIDE [14] para descomponer el error y la estratificación iterativa [15] para particiones conscientes de grupos.

Tabla I
LOS TRES DOMINIOS TRAS LA CURACIÓN. LADO MEDIANO DE OBJETO
MEDIDO SOBRE EL POOL DE ENTRENAMIENTO DE 1280 PX.

Dataset	Vista	Imágenes	Obj. med.	% small
TACO	mano	1,500	171 px	25
RoLID-11K	dashcam	11,564	22 px	84
UAVVaste	dron	772	72 px	66

III. DATASETS, AUDITORÍA Y CURACIÓN

Ingerimos los tres datasets del alcance mediante un pipeline tipo medallón (raw→bronze→silver→gold) con manifiestos por capa y linaje SHA-256; la Figura 1 resume el flujo completo, de la ingesta verificada al contrato de evaluación.

La Tabla I resume los dominios y la Figura 2 muestra el eje que los separa: la escala del objeto.

Hallazgos de la auditoría. Verificaciones sistemáticas (hashing perceptual, verificación de marcos EXIF, cruce de splits) destaparon siete defectos que corregimos o documentamos: (H1) los nombres de archivo de TACO colisionan entre lotes (92 % de las imágenes comparte nombre con otro lote); (H2) ~37 % de las imágenes de TACO trae rotaciones EXIF pendientes, con cajas anotadas sobre el marco *rotado*; (H3) las carpetas de la distribución de RoLID no codifican la hora de captura; (H4) **los splits oficiales de RoLID fugan a nivel de video**: 22 de 84 videos de origen abarcan varios splits y el 58.2 % de los cuadros de test comparte video con el entrenamiento —cuadros casi duplicados (87 % de redundancia visual por hash perceptual) convierten esto en fuga de escena que infla los baselines publicados; (H5) una imagen está duplicada entre val y test oficiales; (H6) el split oficial de UAVVaste también contiene un par casi duplicado que cruza train/test; (H7) los marcos de anotación son inconsistentes entre datasets —TACO anota sobre el marco rotado por EXIF mientras que cinco fotos de mano de UAVVaste anotan el marco crudo—, por lo que los píxeles se materializan por imagen en el marco que coincide con las dimensiones declaradas, con los metadatos EXIF removidos.

Curación. Silver aplica cinco correcciones (duplicado removido de val, categoría fantasma eliminada, identidad por ruta completa, marcado de caja degenerada y de duplicados MD5), define una taxonomía de dos niveles —*litter* (1 clase, todos los datasets) y clases de material de TACO en dos variantes paralelas, **A: 6 clases** (con vidrio, marginal con 38 instancias proyectadas de test) y **B: 5 clases** (sin vidrio)— y congela cuatro esquemas de split con unidades conscientes de grupo: grupos visuales pHash para TACO/UAVVaste y *video de origen* para RoLID. Los splits de TACO usan estratificación iterativa [15]; cada clase cae a menos de 0.1 puntos del objetivo de 15 % de test. Para RoLID mantenemos *ambos* esquemas, el oficial (con fuga, por comparabilidad) y el por-video (0 % de fuga), lo que habilita la cuantificación pareada de la inflación.

IV. MÉTODOS

P0 — pipeline clásico afinado. (1) *Faster R-CNN* (ResNet-50-FPN, preentrenado en COCO) bajo dos estrategias de transferencia —backbone congelado contra descongelar `layer4`— con warmup lineal, recorte de gradiente y early stopping sobre el AP₅₀ de validación. (2) *FCN-ResNet18* para segmentación binaria basura/fondo sobre los polígonos rasterizados de TACO (conv 1×1 + conv transpuesta $\times 32$ con inicialización bilineal, entropía cruzada ponderada por clase). (3) *Transfer learning con VGG-16* sobre recortes de 224 px basura/fondo (dos estrategias $\times$ dos tasas de aprendizaje), sustrato de los paneles de interpretabilidad CAM [10], Grad-CAM [11] y Guided Backpropagation [12]. (4) Un *análisis de cobertura de anclas*: las anclas base de FPN (32–512 px) contra las distribuciones medidas de tamaño de objeto, más mapas de objectness del RPN del modelo dashcam entrenado —una explicación mecanicista de la brecha de objetos pequeños.

P1 — referencia moderna. YOLOv11n [13] entrenado por dominio a 640 px (y 1024 px para la ablación de resolución), usado para llenar la matriz cross-domain 3×3 , el par oficial-contra-por-video de la fuga y la comparativa de variantes 6-contra-5 clases.

Contrato de evaluación. Una sola fuente de verdad métrica: las predicciones de todos los modelos se evalúan con herramientas COCO contra los mismos ground truths congelados; el test se toca una vez por experimento con los pesos de mejor validación; las predicciones guardadas alimentan la descomposición de errores TIDE [14].

V. CONFIGURACIÓN EXPERIMENTAL

Diecinueve corridas (11 de P0, 8 de P1) ejecutadas en dos carriles: Apple M-series (MPS) para VGG/FCN/YOLO y CUDA (Colab A100) para Faster R-CNN y las corridas YOLO pesadas —el perfilado mostró iteraciones sanas de Faster R-CNN de ~95 s en MPS (las entradas de tamaño variable fuerzan recompilación de kernels por forma) contra ~0.3 s en CUDA; un guardián de presupuesto en horas proyectó el costo total tras la primera época y desvió automáticamente las corridas inviables. Presupuestos: topes generosos de épocas (50–150) con early stopping (paciencia 8–30) y curvas de validación; semillas fijas; checkpoints por época con reanudación. Las imágenes se materializan a lado máximo de 1280 (Lanczos, JPEG q95) en el marco de anotación (H7). La Figura 3 muestra las trayectorias de validación de las ocho corridas YOLO: convergencia limpia, early stopping actuando y la separación por dominio y resolución.

Los exports multiclase excluyen *negativos envenenados* —imágenes cuyos únicos objetos pertenecen a clases excluidas— en lugar de entrenarlos como fondo (1/38/60 imágenes para las variantes de 1/6/5 clases).

VI. RESULTADOS

Cada número de esta sección lo genera la notebook de evaluación consolidada a partir de las predicciones de test guardadas contra los ground truths congelados; ninguna métrica se transcribe a mano.




Figura 1. Pipeline de punta a punta. Los datos fluyen por una arquitectura medallón con linaje SHA-256 (etiquetas de flecha: números de notebook); el entrenamiento corre en dos carriles gobernados por guardianes automáticos; todos los modelos se evalúan bajo un solo contrato métrico.




Figura 2. Distribución acumulada del lado del objeto por dominio. La mediana de RoLID (22px) cae bajo el ancla FPN mínima de 32px: el régimen que explica la matriz cross-domain y motiva la ablación de resolución.




Figura 3. AP₅₀ de validación por época de las ocho corridas YOLOv11n.

VI-A. Matriz cross-domain

La Figura 4 presenta el resultado central. Dentro de dominio, los tres modelos YOLOv11n promedian 0.639 de AP₅₀; entre dominios la cifra se desploma a 0.118: una **degradación de 82 %**. La matriz es fuertemente asimétrica: el dominio dashcam es una isla (AP₅₀ ≤ 0,064 en ambas direcciones), mientras que mano→dron transfiere sorprendentemente bien (0.527, reteniendo el 68 % del puntaje in-domain del dron). El patrón señala a la *escala del objeto* antes que a la apariencia: los objetos de TACO y UAVvaste (medianas de 171 y 72px) caen dentro del rango de anclas de FPN, mientras que la mediana de 22px de RoLID queda por debajo del ancla mínima de 32px —consistente con nuestro análisis de cobertura de anclas y con que AP_S colapsa más fuerte (AP_S diagonal: 0.056 / 0.279 / 0.374).




Figura 4. Matriz cross-domain en test (YOLOv11n @640): AP₅₀ (izquierda) y AP_S (derecha). Filas: dominio de entrenamiento; columnas: dominio de test. Media in-domain 0.639 contra 0.118 cruzada.

Tabla II
CUANTIFICACIÓN DE LA FUGA EN RoLID-11K (AP₅₀ DE TEST, YOLOv11n @640).

Split de entrenamiento	Test	AP ₅₀
oficial (58 % fuga)	oficial	0.620
por video (0 % fuga)	por video	0.695
oficial (58 % fuga)	por video	0.844

VI-B. Inflación por fuga en RoLID-11K

La Tabla II aparea los protocolos oficial (58 % de fuga de video) y por-video (0 %). Sobre el *mismo* test limpio por-video, el modelo entrenado con el split oficial —que vio otros cuadros de esos mismos videos de test— obtiene 0.844 de AP₅₀ contra 0.695 del modelo entrenado limpio: una **inflación relativa de +21 %** atribuible a memorización de escena y no a generalización (el 87 % de los pares de cuadros intra-video son visualmente redundantes por hash perceptual). Los baselines publicados sobre el protocolo oficial deben leerse con este sesgo presente; el split consciente de grupos lo elimina a costo cero.

VI-C. Familias bajo el mismo protocolo

La Tabla III compara Faster R-CNN (41.3 M de parámetros) y YOLOv11n (2.6 M) sobre splits y ground truths idénticos. En tareas de una sola clase el modelo 16× más pequeño queda a 1–4 puntos de AP₅₀ (0.695 contra 0.707 en dashcam; 0.442 contra 0.483 en mano), lo que respalda el despliegue ligero; en clasificación de materiales la brecha se abre a 5–9 puntos. Descongelar `layer4` eleva a Faster R-CNN en +3.7 de AP₅₀ sobre el backbone congelado (0.483 contra 0.446).




Figura 5. Interpretabilidad del clasificador de recortes: una fila por dominio (dashcam, mano, dron) con Grad-CAM y Guided Backpropagation. La activación se concentra en el objeto incluso en los recortes de 22 px.

Tabla III
FAMILIAS DE MODELOS SOBRE SPLITS IDÉNTICOS (MÉTRICAS DE TEST).
FRCNN = FASTER R-CNN R50-FPN CON LAYER4 DESCONGELADA.

Datos	Modelo	AP ₅₀	AP	AP _S
TACO 1 clase	FRCNN	0.483	0.323	0.073
	YOLOv11n	0.442	0.318	0.056
RoLID por video	FRCNN	0.707	0.277	0.281
	YOLOv11n	0.695	0.279	0.279
TACO 6 clases	FRCNN	0.246	0.154	0.029
	YOLOv11n	0.157	—	—
TACO 5 clases	FRCNN	0.244	0.155	0.024
	YOLOv11n	0.192	—	—

Nuestro YOLO de 5 clases (0.192 de mAP₅₀) es consistente con el 19.5 de TrashDet en un subconjunto comparable de TACO [7], confirmando que las cifras absolutas del problema son estructuralmente bajas. Los modelos complementarios de P0 cierran el cuadro: FCN-ResNet18 alcanza 0.577 de IoU de test en segmentación binaria de basura, y el clasificador de recortes VGG-16 llega a 97.8 % de exactitud de test, dando el sustrato para la evidencia CAM/Grad-CAM de que la red atiende al objeto y no al contexto (Figura 5).

VI-D. Resolución y granularidad de clases

La Tabla IV muestra la ablación 640→1024. Las ganancias se concentran exactamente donde los objetos son más pequeños: +8.3 de AP₅₀ y +5.8 de AP_S en dashcam, contra +3.2 y +3.9 en mano —la resolución es la palanca efectiva más barata para el régimen de objeto pequeño. En granularidad de

Tabla IV
ABLACIÓN DE RESOLUCIÓN (YOLOv11N, TEST).

Dominio	AP ₅₀		AP _S	
	640	1024	640	1024
TACO	0.442	0.474	0.056	0.096
RoLID	0.695	0.779	0.279	0.337




Figura 6. Descomposición de errores TIDE por modelo (dAP recuperado al corregir cada tipo de error). Cls domina en los multiclase; Bkg+Miss en los de una clase.

clases, excluir la clase marginal de vidrio (38 instancias de test, AP₅₀ de 0.049 cuando se mantiene) mejora el puntaje global de 5 clases a 0.192 contra 0.157 con 6 clases, con una media de +0.014 de AP₅₀ en las cinco clases compartidas (máxima en metal, +0.077): mantener una clase severamente sub-representada les cobra impuesto a sus hermanas.

VI-E. Descomposición del error

La Figura 6 descompone el error con TIDE para los 13 detectores. Emergen tres regímenes. Los modelos multiclase están dominados por el error de *clasificación* (hasta 24.6 dAP en el YOLO de 5 clases, contra apenas 1.7 de localización): encontrar la basura no es el cuello de botella — nombrarla sí. Los modelos de una clase en mano reparten su error entre falsos positivos de fondo y objetos no detectados (~11–13 dAP cada uno). Los modelos dashcam in-domain, contra la intuición, casi no pierden por objetos no detectados (dAP_{Miss} ≤ 3.9): los objetos de 22 px sí se encuentran, y el error residual lo dominan las confusiones con el fondo — evidencia de que el colapso cross-domain de la Figura 4 nace de las representaciones y no de un piso irreuperable de recall.

VI-F. Resultados cualitativos fuera de distribución

La Figura 7 muestra la demo por lotes (notebook 07) sobre una sesión de diez imágenes descargadas de internet, ajenas a los tres datasets. Con umbrales conservadores (0.25 para

YOLO, 0.5 para Faster R-CNN), los patrones del protocolo cuantitativo reaparecen fuera de distribución: Faster R-CNN propone más candidatos que YOLOv11n en las diez imágenes (211 contra 87 detecciones en total; 45 contra 15 en la escena más densa), el FCN estima entre 3 y 16 % de píxeles de basura por escena, y el clasificador VGG confirma cada recorte con $P(\text{litter}) \geq 0.99$, con Grad-CAM atendiendo al objeto y no a su contexto. Estas imágenes son evidencia ilustrativa, no métrica: no poseen anotaciones.

VII. DISCUSIÓN Y LIMITACIONES

Tres hallazgos organizan la evidencia. **Los detectores de basura no viajan.** La caída de 82 % entre dominios, con dashcam aislada y mano↔dron parcialmente compatibles, se explica primero por la escala del objeto: los dominios cuyos tamaños caen dentro del rango de anclas del preentrenamiento intercambian algo de conocimiento; el régimen de 22 px de dashcam no intercambia nada. Para despliegues municipales con sensores mixtos, el ajuste fino por dominio —o al menos la adaptación de resolución— sigue siendo obligatorio; un modelo universal de basura aún no es realista. **La higiene de los splits cambia conclusiones.** El protocolo oficial de RoLID premia la memorización de escena (+21 % de AP_{50}); los resultados publicados sobre él son optimistas en aproximadamente ese margen, y la corrección (split por video, consciente de grupos) no cuesta nada. Sostenemos que los datasets con estructura de video o ráfaga deberían publicar identificadores de grupo. **Las palancas baratas funcionan.** La entrada de 1024 px recompra +8.3 de AP_{50} en dashcam; un detector de 2.6M de parámetros rinde a pocos puntos de uno de 41.3M en detección de una clase; y TIDE ubica el cuello de botella multiclase en la clasificación del material y no en la localización —lo que sugiere un diseño desacoplado (detector agnóstico a la clase más clasificador de recortes, donde nuestro sustrato VGG alcanza 97.8 % de exactitud) por encima de cabezas de detección cada vez más finas. Limitaciones que ya podemos enunciar: el mAP absoluto de este problema es estructuralmente bajo [7]; nuestro presupuesto de cómputo excluyó detectores transformer (clase CO-DETR), que lideran el benchmark in-domain de RoLID; StreetView-Waste no pudo incluirse (enlaces no disponibles); nuestra propia captura fuera de distribución (Lima) queda como trabajo futuro, igual que la agregación temporal sobre video de dashcam —natural dada la estructura de video que nuestra auditoría expuso.

VIII. CONCLUSIÓN

Auditamos tres datasets públicos de basura, publicamos splits corregidos conscientes de grupos y medimos —bajo un solo contrato de evaluación— qué tan lejos viajan los detectores de basura entre imágenes de mano, dashcam y dron. Las respuestas son concretas: una caída de 82 % de mAP_{50} fuera de dominio con dashcam totalmente aislada; una inflación de +21 % de AP_{50} escondida en los splits oficiales de RoLID-11K; hasta +8.3 de AP_{50} recuperable solo con resolución de entrada; y un detector moderno $16\times$ más pequeño a pocos puntos de Faster R-CNN en basura de una

clase. La descomposición del error muestra que las batallas restantes son la discriminación del fondo y la clasificación del material, no la localización. El pipeline completo —de la ingesta con checksums a las tablas generadas—, los pesos y una demo en vivo son públicos; los detectores transformer, la agregación temporal sobre video de dashcam y nuestra captura fuera de distribución planificada en Lima son los siguientes pasos naturales.

REPRODUCIBILIDAD

Se publican el código, las notebooks (de la ingesta a la evaluación), los splits auditados, los pesos entrenados y un video demo seccionado; se documentan tres rutas de reproducción (demo con pesos preentrenados, regeneración de métricas desde los artefactos publicados en ~ 10 minutos, y reentrenamiento completo desde los datos públicos). Los datasets se descargan de sus fuentes oficiales con verificación de checksums.

REFERENCIAS

- [1] P. F. Proença and P. Simões, “TACO: Trash annotations in context for litter detection,” *arXiv preprint arXiv:2003.06975*, 2020.
- [2] T. Wu, Q. Xu, X. He, O. Weekes, J. Brown, and W. Duan, “RoLID-11K: A dashcam dataset for small-object roadside litter detection,” in *IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*, 2026.
- [3] M. Kraft, M. Piechocki, B. Ptak, and K. Walas, “Autonomous, onboard vision-based trash and litter detection in low altitude aerial images collected by an unmanned aerial vehicle,” *Remote Sensing*, vol. 13, no. 5, p. 965, 2021.
- [4] D. J. Paulo, J. Martins, H. Proença, and J. C. Neves, “StreetView-Waste: A multi-task dataset for urban waste management,” in *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2026.
- [5] S. Majchrowska, A. Mikołajczyk, M. Ferlin, Z. Klawikowska, M. A. Plantykw, A. Kwasigroch, and K. Majek, “Deep learning-based waste detection in natural and urban environments,” *Waste Management*, vol. 138, pp. 274–284, 2022.
- [6] D. Bashkirova, M. Abdelfattah, Z. Zhu, J. Akl, F. Alladkani, P. Hu, V. Ablavsky, B. Calli, S. A. Bargal, and K. Saenko, “ZeroWaste dataset: Towards deformable object segmentation in cluttered scenes,” in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
- [7] T. Tran and B. Hu, “TrashDet: Iterative neural architecture search for efficient waste detection,” in *IEEE/CVF Winter Conference on Applications of Computer Vision Workshops (WACVW)*, 2026.
- [8] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.
- [9] J. Long, E. Shelhamer, and T. Darrell, “Fully convolutional networks for semantic segmentation,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.
- [10] B. Zhou, A. Khosla, A. Lapedriza, A. Oliva, and A. Torralba, “Learning deep features for discriminative localization,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [11] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *IEEE International Conference on Computer Vision (ICCV)*, 2017.
- [12] J. T. Springenberg, A. Dosovitskiy, T. Brox, and M. Riedmiller, “Striving for simplicity: The all convolutional net,” in *ICLR Workshop*, 2015.
- [13] G. Jocher and J. Qiu, “Ultralytics YOLO11,” <https://github.com/ultralytics/ultralytics>, 2024.
- [14] D. Bolya, S. Foley, J. Hays, and J. Hoffman, “TIDE: A general toolbox for identifying object detection errors,” in *European Conference on Computer Vision (ECCV)*, 2020.
- [15] K. Sechidis, G. Tsoumakas, and I. Vlahavas, “On the stratification of multi-label data,” in *Machine Learning and Knowledge Discovery in Databases (ECML PKDD)*, 2011.




Figura 7. Demo cualitativa en imágenes web fuera de distribución (tres de las diez de la sesión): original con el origen del recorte del Grad-CAM marcado en punteado, detecciones YOLOv11n y Faster R-CNN, máscara FCN y explicación Grad-CAM del clasificador de recortes. Imágenes descargadas aleatoriamente de internet, sin metadata de autoría embebida, usadas únicamente con fines ilustrativos; serán reemplazadas por capturas propias (Lima) en una revisión futura.